




Curso IMPY Tech

Aula 6

Fundamentos de Aprendizado Estatístico

Gustavo Sousa Cardoso

Nome dos auxiliares



impy
tech

01 Introdução

- Objetivo
- Hipóteses
- Modelos

02 Estatística

- Teste de hipóteses
- Valor p
- Métricas

03 Problemas


- Regressão
- Classificação

04 Métodos

- Regressão Linear
- Regularização
- Deep Learning



Introdução



$$Y = f(X) + \epsilon.$$

Em termos gerais, o aprendizado estatístico consiste em técnicas matemáticas e computacionais para representar dados.

- Em geral gostaríamos de fazer previsões e inferências, e gostaríamos que essas previsões e inferências sejam precisas.
- Para obtermos sucesso nessa empreitada, o caminho sempre é buscar um modelo que generalize bem os dados.

- Assumindo que $Y = f(X) + e$, há dois objetivos diferentes:
- Inferência vai no sentido de entender como X modela Y .
- Previsão vai no sentido de prever o valor de Y para X que ainda não foram vistos.

- É muito importante ter em mente quais hipóteses estão sendo feitas sobre os dados.
- Em primeiro lugar: Há um padrão para ser aprendido.
- Em Segundo: Esse padrão pode ser representado matematicamente.
- E em terceiro: Nosso modelo matemático é coerente com a realidade.

- A maneira mais simples de aprendizado estatístico é feito através de modelos paramétricos.
- Através de suposições e hipóteses sustentadas por conhecimento externo sobre o problema.
- Bastante comum na física onde os fenômenos são bem conhecidos.

- O fato do modelo ser conhecido e moldado em conhecimento anterior, faz com que ele seja interpretável.
- Porém, inevitavelmente o modelos terá o viés do conhecimento externo utilizado.

- Regressão linear é a técnica mais conhecida para ajustes. Ela faz a suposição de que há uma relação linear entre as variáveis.

$$f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p.$$

- A partir das variáveis, é fundamental para a qualidade do ajuste que as variáveis que explicam os dados estejam presentes no modelo.
- É importante mencionar o fato de que não há a exigência de os dados aparecerem “puros” no modelos, explicando relações não necessariamente lineares entre os dados.


- Há um problema inerente do aumento da flexibilidade que é o overfitting.
- A formulação matemática da regressão linear garante que a função gerada é a função que minimiza o erro quadrático.

$$E \left(y_0 - \hat{f}(x_0) \right)^2 = \text{Var}(\hat{f}(x_0)) + [\text{Bias}(\hat{f}(x_0))]^2 + \text{Var}(\epsilon).$$

- Uma das maiores vantagens dos modelos paramétricos consiste no fato de que eles são completamente interpretáveis.
- Por Outro lado, modelos mais robustos com mais parâmetros “aprendíveis” tendem a ter melhor precisão, mas com menos interpretabilidade.



Estatística



- É uma ferramenta estatística usada para validar uma hipótese sobre os dados, em geral é uma ferramenta de inferência.
- A conta é feita a supondo que a hipótese nula é verdadeira e calculando o quão improvável é que isso dados os dados.

- Estamos concentrados em saber se coeficiente em questão é relevante para explicar os dados (ou seja, diferente de zero)
- Na prática buscamos rejeitar a hipótese nula, que no caso de aprendizado supervisionado é a hipótese de que o dado coeficiente é diferente de zero.

- Uma vez posto o teste de hipóteses, o p valor de um coeficiente é apenas a probabilidade dos valores observados acontecerem dado que o coeficiente é zero.
- Ou seja, quanto menor, melhor.


- Acontece uma coisa muito perigosa quando se tem muitos preditores em modelos muito complexos.
- Um p valor muito baixo não significa que necessariamente aquele coeficiente explica os dados
- Em bom português: correlação não implica causalidade, mas é mais profundo que isso

- Dentre todas as métricas que o stats model exibe, as principais são as sobre o R^2 e o R^2 Ajustado que medem a qualidade do ajuste
- A estatística F diz sobre a hipótese de que todos os coeficientes sejam 0.

- Métricas de precisão.
- Capacidade de generalização.



Problemas



- Em geral podemos separar os problemas de aprendizado estatístico em 2 tipos bem definidos.
- Os problemas de regressão, cuja saída é um valor.
- E os problemas de Classificação, cuja saída é uma classe.


- Os modelos não conseguem classificar as entradas diretamente, então o que é feito em geral é um cálculo do tipo “Qual é a probabilidade dessa entrada pertencer a cada classe dado seus atributos?”
- Dessa forma um problema de classificação é traduzido para um problema com saída numérica que os métodos trabalham

- Porém os métodos puros de regressão não tem um limite claro e não tem como saída uma probabilidade, por isso se usa a regressão logística.

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X.$$



Métodos



- Treino são os dados que o modelo vai usar para de fato se ajustar.
- Validação é o conjunto usado para validar o treino, selecionar o melhor modelo e tunar hiper parâmetros.
- Teste é onde os modelo finais vão ser avaliados

- A partir dos moldes da regressão linear, são definidos vários outros métodos:
- Técnicas de seleção de preditores
- Regressão Linear Múltipla.
- Uso de variáveis categóricas.
- Termos de interação e relações não lineares.

- A regularização envolve manipular o ajuste em uma direção desejável.
- Na formulação original, a regressão não tem nenhum viés, então por que introduzir viés?
- De volta ao trade-off viés variância.

- A ideia é penalizar uma coisa específica alterando a função de perda, ou seja, o que está sendo minimizado

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 = \text{RSS} + \lambda \sum_{j=1}^p \beta_j^2,$$

- A única diferença em relação ao Ridge é que em vez de penalizar o quadrado dos coeficientes, está sendo penalizado o módulo.

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j| = \text{RSS} + \lambda \sum_{j=1}^p |\beta_j|.$$

- Saindo do ponto de vista dos modelos paramétricos, há uma infinidade de modelos não paramétricos, ou seja, onde não há uma suposição do formato dos dados.

- O preço é pago em variância, apesar da redução do viés. Os Métodos são mais flexíveis, porém menos interpretáveis e mais sensíveis a pequenas alterações nos dados.

- KNN.
- Árvores de Decisão.
- SVM.
- Random Forests.
- E muitos outros mais...

- De volta ao trade-off interpretabilidade x previsão

TECNOLOGIA

Q BUSCAR

China lança maior IA de código aberto do mundo e aumenta pressão sobre OpenAI e Anthropic


O Kimi K3, da startup Moonshot, reúne 2,8 trilhões de parâmetros, promete desempenho próximo aos modelos mais avançados dos Estados Unidos e reforça o avanço chinês na corrida global pela inteligência artificial.



Por Reuters — Pequim

17/07/2026 12h58 · Atualizado há 6 dias

- De volta ao problema original, supor que $y = f(X) + e$ e tentar aprender f .
- Caixas pretas pouco ou quase nada interpretáveis de maneira geral, mas ainda é possível imbuir conhecimento prévio.
- Mas o Avanço é quase empírico, se usa o que mais funciona, mas não se sabe explicar o por que funciona



Obrigado!

Avalie a aula



Professor
e-mail's (opcional)

Referências bibliográficas:

- Pense em Python (1): Capítulo 1 e Capítulo 2
- Python for Data Analysis (2): Seções 2.3 e 2.4

Leituras Adicionais

- Link 1
- Link 2

Exercícios

- Jupyter de exercícios X
- Link para exercícios



Livro 1



Leitura adicional

